

# RNN 変換モデルを用いた 高階論理からの文生成

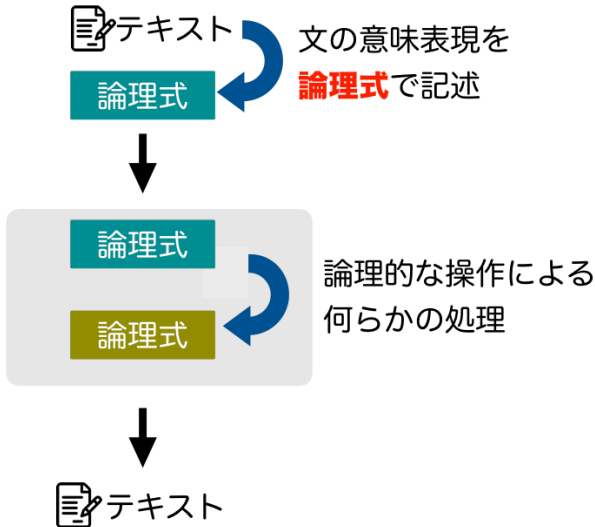
馬目 華奈

お茶の水女子大学 戸次研究室

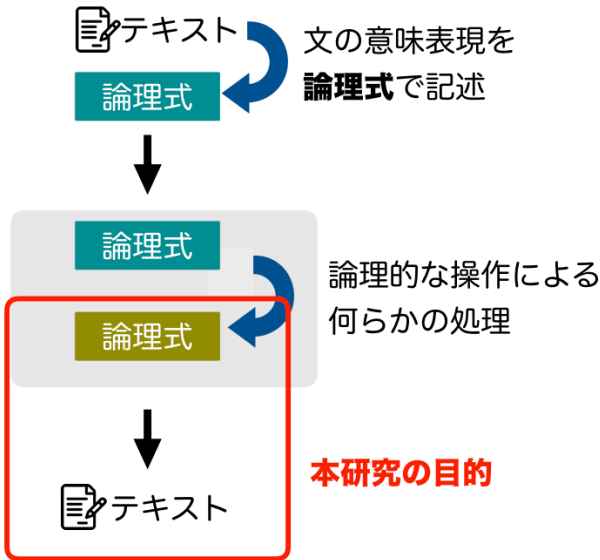
言語処理学会

March 13, 2018

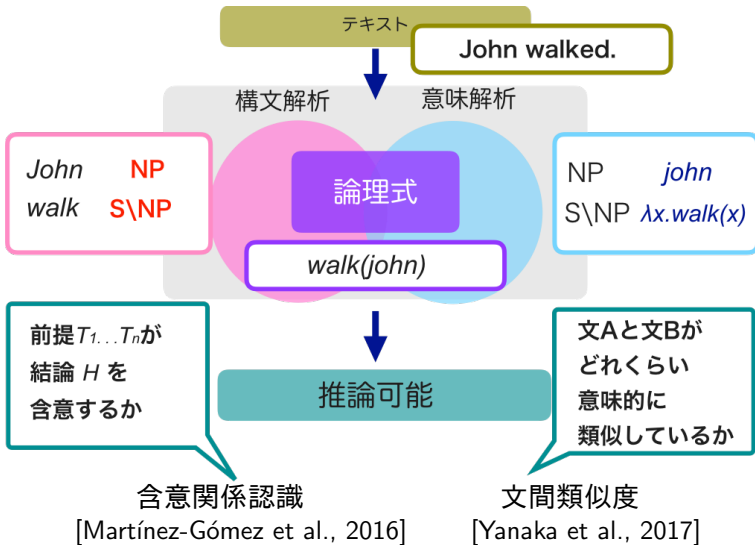
## 本研究の目的



## 本研究の目的




# 意味表示としての論理式

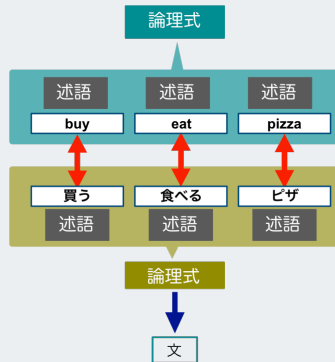


# 論理式→文の応用例


## テキスト平易化



## 翻訳




# 研究概要



- RNN 系列変換モデルを用いて  
高階論理式から文を生成する手法を提案.
- embedding の際, 4 種の手法を検討する.  
(記号, トークン, 木構造, グラフ)

## 文から高階論理式への変換



- RNN 系列変換モデルを用いて  
高階論理式から文を生成する手法を提案.
- embedding の際, 4 種の手法を検討する.  
(記号, トークン, 木構造, グラフ)

# 関連研究：ccg2lambda に基づく論理式による文の意味表現

Mineshima+ [EMNLP2015]

Martínez-Goméz+ [ACL2016]

	ate	Pizza	
	$(S \backslash NP) / NP$	NP	
Bob	$\lambda y \lambda x \exists e. \text{eat}(e, x, y)$	pizza	>
NP	$S \backslash NP$		
bob	$\lambda x. \exists e. \text{eat}(e, x, \text{pizza})$		<
	S		
	$\exists e. \text{eat}(e, \text{bob}, \text{pizza})$		



テキスト

CCG  
導出木

構文解析

論理式

意味解析


<https://github.com/mynlp/ccg2lambda>

含意関係認識

論理推論



# embedding 手法の提案



- RNN 系列変換モデルを用いて高階論理式から文を生成する手法を提案.
- embedding の際, 4 種の手法  
(記号, トークン, 木構造, グラフ) を検討する.

## 提案手法：記号区切りとトークン区切り

Bob walked の論理式：

$\text{exists } x.(\text{Bob}(x) \ \& \ \text{exists } e.(\text{walk}(e) \ \& \ (\text{Subj}(e) = x)))$


### 1：記号ごとに区切る

$[e, x, i, s, t, s, \_, x, \_, (, B, o, b, \_, (, x, ), \dots]$

### 2：トークンごとに区切る

$[\text{exists}, x, (, \text{Bob}, (, x, ), \&, \text{exists}, e, (, \dots]$

## 提案手法：木構造のベクトル化




### 木構造を用いたベクトル

[exists,  $x$ , &, =,  
Bob,  $x$ , exists,  $e$ , &, ...]

- 論理式をポーランド記法に変換する  
(論理演算子を前にもってくる)
- pre-order の深さ優先探索でたどる

# 提案手法：グラフ構造のベクトル化




## グラフ構造を用いたベクトル

[exists,  $x$ ,  $x$ , &, Bob, &, =  
, Subj, walk...]

- 論理式をポーランド記法に変換する  
(論理演算子を前にもってくる)
- 同じ変数をさす様に edge を変更
- pre-order の深さ優先探索でたどる


# RNN 系列変換モデル



- RNN 系列変換モデルを用いて高階論理式から文を生成する手法を提案.
- embedding の際, 4 種の手法を検討する.  
(記号, トークン, 木構造, グラフ)

# 系列変換モデル [Sutskever et al., 2014]

- 入出力がシーケンスとなるニューラルネットのモデル
- エンコーダ：入力列を RNN ニューラルネットにより隠れ状態ベクトルに変換
- デコーダ：隠れ状態ベクトルを初期値とし、隠れ状態と自身のこれまでの出力結果をもとに次のトークンを生成



## データセットの作成

- SNLI(The Stanford Natural Language Inference Corpus) [Bowman et al., 2015] を用い論理式と文のペアを作成
- 60 単語以内の文例を対象 train:9140/dev:2285/test:1500
- ccg2lambda を用いる

	<u>ate</u>	<u>Pizza</u>	
	$(S \backslash NP) / NP$	$NP$	
<u>Bob</u>	$\lambda y \lambda x \exists e. eat(e, x, y)$	<u>pizza</u>	
<u>NP</u>	$S \backslash NP$		>
<u>bob</u>	$\lambda x. \exists e. eat(e, x, pizza)$		
	<u>S</u>		<
	$\exists e. eat(e, bob, pizza)$		

テキスト(文)

高階論理式

## 実験設定

- 系列変換モデルによる文生成（入力：論理式，出力：文）
- トークンベースの LSTM の出力を 256 次元に設定

	記号	トークン	木構造	グラフ
入力語数	70	5,118	5,107	4,991
出力語数	78	7,214	7,214	7,214
最長入力列	2,097	699	451	259
最長出力列	270	55	53	53

### 環境，ライブラリ

- tsubame サーバ（メモリ 240GiB, GPU × 4）
- python3 系ライブラリ（Keras, nltk）



# 評価方法

## BLEU による評価

$$score = BP \exp \left( \sum_{i=1}^N \frac{1}{N} \log P_n \right)$$

$$BP = \begin{cases} 1 & (c \geq r) \\ \exp \left( 1 - \frac{r}{c} \right) & (c < r) \end{cases}$$

$$P_n = \frac{\sum_{i=0} \text{出力文 } i \text{ 中と解答文 } i \text{ 中で一致した } n\text{-gram 数}}{\sum_{i=0} \text{出力文 } i \text{ 中の全 } n\text{-gram 数}}$$

## 実験結果

### BLEU 評価

指標	記号	トークン	木構造	グラフ
BLEU	34.9	39.7	41.8	44.7

入力論理式：

`exists x.(_towel(x) & exists e.(_pink(e) & (Subj(e) = x)) & exists e.(_blue(e) & (Subj(e) = x) & _striped(e)))`

文	The towel is pink and blue striped.
記号単位	A horse is talking to each other.
トークン単位	A guy snipping a ladys hair.
木構造	The blue is blue and blue .
グラフ	A blue tractor is wearing blue .

## まとめ

- RNN 系列変換モデルを用いて高階論理式から文を生成する手法を提案した.
- 実験をする際, ccg2lambda を用いてデータセットを作成した.
- 提案手法の評価を行った結果, BLEU スコアは, トークン単位で区切り, 論理式の計算の順序を考慮することで高くなった.

## 今後の課題

- 他の意味表現からの文生成との比較を行う.
- 他のデータセット（英語，日本語）でも行う.
- 逆変換（文→論理式）を行い，モデルを評価する.
- 評価方法に，文類似度を使用するなど文生成における評価方法を工夫する.
- アテンション付き系列変換モデルやコピー機構を用いるなどモデルの改良に取り組む.

## 参考文献 I

- Lasha Abzianidze. A Tableau Prover for Natural Logic and Language. In *Proc. of EMNLP*, 2015.
- Daisuke Bekki. *A Formal Theory of Japanese Grammar: The Conjugation System, Syntactic Structures, and Semantic Composition*. Kuroshio, 2010. (In Japanese).
- Samuel R. Bowman, Gabor Angeli, Christopher Potts, and Christopher D. Manning. A large annotated corpus for learning natural language inference. In *Proc. of EMNLP*, 2015.
- Ioannis Konstas, Srinivasan Iyer, Mark Yatskar, Yejin Choi, and Luke Zettlemoyer. Neural AMR: Sequence-to-Sequence Models for Parsing and Generation. In *Proc. of ACL*, 2017.
- Pascual Martínez-Gómez, Koji Mineshima, Yusuke Miyao, and Daisuke Bekki. ccg2lambda: A Compositional Semantics System. In *Proc. of ACL System Demonstrations*, 2016.
- Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. BLEU: a Method for Automatic Evaluation of Machine Translation. In *Proc. of ACL*, 2002.
- Mark Steedman. Surface Structure and Interpretation. In *The MIT Press*, 1996.

## 参考文献 II

- Ilya Sutskever, Oriol Vinyals, and Quoc V Le. Sequence to Sequence Learning with Neural Networks. In *Proc. of NIPS*, 2014.
- Mingzhe Wang, Yihe Tang, Jian Wang, and Jia Deng. Premise selection for theorem proving by deep graph embedding. In *Proc. of NIPS*, 2017.
- Hitomi Yanaka, Koji Mineshima, Pascual Martínez-Gómez, and Daisuke Bekki. Determining Semantic Textual Similarity using Natural Deduction Proofs. In *Proc. of EMNLP*, 2017.